

Simulação de uma Fila M/M/1 com Falhas e Reparos Aplicada a um Gateway de Borda

Rafaella Laureano Dias e Brithany Michelle Oliva Chuquimia
TP 547 – Princípios de Simulação de Sistemas de Comunicação
Instituto Nacional de Telecomunicações – Inatel
Santa Rita do Sapucaí, MG, Brasil

Abstract—Este trabalho modela e simula uma fila M/M/1 cujo servidor pode falhar e entrar em reparo. As chegadas seguem um processo de Poisson com taxa λ , os atendimentos possuem duração exponencial com taxa μ , as falhas ocorrem com taxa α e os reparos têm duração exponencial com taxa β . Durante o reparo, as chegadas continuam e as tarefas permanecem armazenadas. O estudo de caso representa um gateway de borda que processa lotes de dados de dispositivos IoT. No cenário-base, foram adotados $\lambda = 4,2$ lotes/h, $\mu = 6$ lotes/h, $\alpha = 0,3$ falhas/h e $\beta = 3$ reparos/h. A simulação foi implementada por agendamento de eventos, com período de aquecimento, 20 replicações independentes e intervalos de confiança de 95%. O resultado do cenário-base foi $E[N] = 3,89 \pm 0,43$ tarefas e $E[T] = 0,928 \pm 0,097$ h, em concordância com a solução numérica da cadeia de Markov, que forneceu $E[N] = 3,901$ e $E[T] = 0,929$ h. A aproximação por taxa efetiva subestimou essas métricas. Comparações adicionais mostraram que a falha elevou o tempo médio em aproximadamente 72% em relação à M/M/1 confiável; a M/M/2 reduziu o atraso para cerca de 0,190 h; serviços mais variáveis aumentaram a ocupação e o atraso; e buffers menores reduziram o atraso dos lotes aceitos ao custo de bloqueio. Os resultados confirmam que disponibilidade, variabilidade do serviço, redundância e armazenamento precisam ser analisados em conjunto.

Index Terms—Simulação de eventos discretos, teoria de filas, servidor não confiável, falhas e reparos, computação de borda, buffer finito.

I. INTRODUÇÃO

Sistemas de filas são usados para representar pacotes aguardando transmissão, tarefas esperando processamento e requisições disputando recursos computacionais. Em computação de borda, o processamento é deslocado para próximo das fontes de dados para reduzir latência e tráfego até a nuvem [1]. Essa proximidade torna o desempenho do nó de borda relevante para aplicações sensíveis a atraso, mas também expõe o serviço a reinicializações, indisponibilidades e manutenção.

Filas com servidor temporariamente indisponível formam uma classe consolidada de modelos. Fuhrmann e Cooper estudaram decomposições estocásticas em filas M/G/1 com períodos de indisponibilidade [2]. Sherman e Kharoufeh analisaram uma fila M/M/1 de repetição com servidor não confiável e derivaram condições de estabilidade e métricas estacionárias [3]. Modelos posteriores incorporaram serviço em lote, servidor de reserva, férias e reparos [4]. Embora esses modelos sejam mais gerais, a configuração M/M/1 com falha

e reparo é suficiente para demonstrar a interação entre carga, disponibilidade e atraso.

O objetivo deste trabalho é construir um simulador de eventos discretos para esse sistema, validar sua implementação e comparar seu desempenho com outras configurações de fila, distribuições de serviço e capacidades de armazenamento. A análise estatística utiliza replicações independentes e intervalos de confiança, prática recomendada para evitar conclusões apoiadas em uma única trajetória aleatória [5], [6].

II. ESTUDO DE CASO

Considera-se um gateway de borda que recebe lotes de dados gerados por dispositivos IoT. Os lotes aguardam em uma fila FIFO e são processados por um servidor lógico. A falha representa travamento de software, reinicialização do sistema ou indisponibilidade temporária do processo responsável pelo tratamento dos dados.

A unidade de tempo é a hora. O cenário-base utiliza

$$\lambda = 4,2, \quad \mu = 6, \quad \alpha = 0,3, \quad \beta = 3. \quad (1)$$

Esses valores correspondem a um intervalo médio entre chegadas de 14,29 min, tempo médio de serviço de 10 min, tempo médio até falha de 3,33 h e tempo médio de reparo de 20 min.

A disponibilidade do servidor é

$$A = \frac{\beta}{\alpha + \beta} = 0,9091, \quad (2)$$

e a capacidade média de atendimento é

$$\mu_{cap} = \mu A = 5,4545 \text{ lotes/h.} \quad (3)$$

Portanto, o cenário é estável porque $\lambda < \mu_{cap}$.

III. MODELAGEM

A. Hipóteses

As chegadas seguem Poisson; os tempos de serviço, falha e reparo são exponenciais e independentes; existe um servidor; a disciplina é FIFO; a falha pode ocorrer com o servidor livre ou ocupado; durante o reparo não há processamento; e novas chegadas continuam ocorrendo.

Quando uma falha interrompe um atendimento, a tarefa permanece associada ao servidor. O trabalho já executado é preservado e o atendimento continua após o reparo. Essa política, denominada *preemptive-resume*, também permite




Fig. 1. Fluxos dos eventos de chegada e partida.

comparar distribuições não exponenciais sem descartar serviço já realizado.

B. Variáveis de estado e entidades

As variáveis de estado são: número total de tarefas $N(t)$, número na fila $N_q(t)$, estado operacional do servidor $Y(t) \in \{U, D\}$, indicador de ocupação $B(t)$ e tempo restante da tarefa em serviço. As entidades são os lotes de dados e o servidor. A fila FIFO constitui a lista de espera.

Os avisos da lista de eventos futuros são (A, t_a) , (D, t_d) , (F, t_f) , (R, t_r) e (E, T_{fim}) , correspondentes a chegada, partida, falha, reparo e encerramento.

C. Eventos

A Fig. 1 apresenta separadamente os fluxos dos eventos de chegada e partida. A Fig. 2 apresenta os fluxos dos eventos de falha e reparo. Em todos os eventos, as estatísticas acumuladas são atualizadas antes da alteração das variáveis de estado, considerando o intervalo transcorrido desde o evento anterior.

D. Estabilidade e aproximação

A condição de estabilidade é

$$\lambda < \mu \frac{\beta}{\alpha + \beta}. \quad (4)$$

A disponibilidade e a capacidade média são exatas para o processo alternante exponencial. Entretanto, substituir o sistema interrompido por uma M/M/1 com

$$\mu_{eff} = \mu \frac{\beta}{\alpha + \beta} \quad (5)$$




Fig. 2. Fluxos dos eventos de falha e reparo.

é apenas uma aproximação para atraso e ocupação. A interrupção cria variabilidade adicional que não é representada por uma única taxa exponencial equivalente.

IV. METODOLOGIA DE SIMULAÇÃO

O relógio avança para

$$t_{prox} = \min(t_a, t_d, t_f, t_r, T_{fim}). \quad (6)$$

Antes de executar o evento, as áreas $\int N(t)dt$ e $\int N_q(t)dt$ são acumuladas. As métricas são

$$E[N] = \frac{1}{T} \int_0^T N(t)dt, \quad E[N_q] = \frac{1}{T} \int_0^T N_q(t)dt, \quad (7)$$

$$X = \frac{N_{saidas}}{T}, \quad E[T] = \frac{E[N]}{X}, \quad E[T_q] = \frac{E[N_q]}{X}. \quad (8)$$

A disponibilidade simulada é $1 - T_{reparo}/T$, a utilização é a fração do tempo em que o servidor está operacional e ocupado, e o bloqueio é a razão entre chegadas rejeitadas e chegadas observadas.

Foram descartadas 100 h de aquecimento e coletadas 1000 h por replicação. Cada cenário usa 20 replicações independentes. Para uma métrica Z , o intervalo de confiança é

$$\bar{Z} \pm t_{0,975,r-1} \frac{s_Z}{\sqrt{r}}. \quad (9)$$

O uso de replicações independentes e intervalos de confiança segue a literatura de análise de saída de simulação [5], [6].

A validação emprega três referências: fórmulas exatas da M/M/1 confiável; disponibilidade $\beta/(\alpha + \beta)$; e uma CTMC truncada nos estados (n, U) e (n, D) , resolvida por $\pi Q = 0$ e $\pi \mathbf{1} = 1$.

TABLE I
VALIDAÇÃO DO CENÁRIO-BASE

Métrica	Simulação	IC95	CTMC	μ_{eff}
$E[N]$	3,8859	0,4275	3,9012	3,3478
$E[N_q]$	3,1199	0,4194	3,2012	2,5778
$E[T]$ (h)	0,9282	0,0968	0,9289	0,7971
$E[T_q]$ (h)	0,7449	0,0957	0,7622	0,6138

V. RESULTADOS

A. Validação e cenário-base

A Tabela I mostra concordância entre simulação e referências analíticas. A aproximação por μ_{eff} subestima ocupação e atraso.

A disponibilidade simulada foi $0,90941 \pm 0,00397$, próxima do valor teórico $0,90909$. A vazão foi $4,1789 \pm 0,0346$ lotes/h, próxima da taxa de entrada, como esperado em um sistema estável e sem bloqueio.

B. Variação dos parâmetros

As Figs. 3 e 4 apresentam as médias e intervalos de confiança. O aumento de λ e α eleva ocupação e atraso; o aumento de μ e β produz o efeito oposto. A divergência entre simulação e aproximação cresce à medida que a carga se aproxima de um, pois os períodos de reparo concentram chegadas sem permitir saídas.




Fig. 3. Impacto das taxas de chegada e serviço.

TABLE II
COMPARAÇÃO ENTRE CONFIGURAÇÕES DE FILA

Sistema	$E[N]$	$E[T]$ (h)	Utilização	Vazão
M/M/1 confiável	2,288	0,546	0,695	4,190
M/M/1 com falhas	3,970	0,940	0,703	4,222
M/M/2 confiável	0,795	0,190	0,349	4,178




Fig. 4. Impacto das taxas de falha e reparo.

C. Comparação entre filas

A Tabela II e a Fig. 5 mostram que as falhas aumentaram $E[T]$ de 0,546 h para 0,940 h, acréscimo de aproximadamente 72%. A M/M/2 reduziu $E[T]$ para 0,190 h. A comparação evidencia que redundância de serviço pode compensar indisponibilidade, embora implique maior capacidade instalada.




Fig. 5. Ocupação e atraso em três configurações.




Fig. 6. Efeito da distribuição do serviço.

D. Distribuição do serviço

Mantendo o mesmo tempo médio, a distribuição determinística produziu $E[T] = 0,637$ h, Erlang-2 resultou em 0,782 h, exponencial em 0,889 h e hiperexponencial em 1,103 h. O resultado é consistente com a fórmula de Pollaczek–Khinchin, segundo a qual o segundo momento do serviço afeta diretamente o tempo de espera em uma M/G/1. No sistema com falhas, a mesma tendência permanece porque maior variabilidade aumenta a chance de longos atendimentos coexistirem com interrupções.




Fig. 7. Bloqueio e atraso para diferentes capacidades.

E. Capacidade de armazenamento

Com $K = 5$, a probabilidade de bloqueio foi 0,0968 e a vazão caiu para 3,788 lotes/h. Para $K = 10$, o bloqueio foi 0,0233; para $K = 20$, 0,00190. O buffer infinito eliminou o bloqueio, mas elevou $E[T]$ para 0,935 h. Assim, buffers menores limitam a ocupação e o atraso dos lotes aceitos, mas transferem o custo para perda de tráfego. Esse compromisso é compatível com estudos de filas finitas e férias do servidor, nos quais a perda depende da carga e do armazenamento [7].

VI. CONCLUSÕES

O simulador reproduziu corretamente a fila M/M/1 confiável, a disponibilidade do processo de falha e reparo e a solução estacionária da CTMC. A aproximação por taxa efetiva foi útil para indicar tendências, mas subestimou ocupação e atraso porque não representa a variabilidade introduzida pelas interrupções.

No cenário de gateway de borda, a indisponibilidade de aproximadamente 9,1% elevou o tempo médio em 72% em relação ao servidor confiável. A adição de um segundo servidor reduziu substancialmente o atraso. Serviços com menor variabilidade apresentaram melhor desempenho, enquanto a

distribuição hiperexponencial foi a mais desfavorável. O armazenamento finito controlou o crescimento da fila, porém introduziu bloqueio e reduziu a vazão.

A principal implicação de projeto é que disponibilidade isolada não determina o atraso. Dimensionamento de capacidade, variabilidade da carga, política de recuperação e tamanho do buffer precisam ser avaliados em conjunto. Como extensão, podem ser incluídas falhas dependentes do estado de ocupação, reparos não exponenciais, servidores redundantes também sujeitos a falhas e prioridades entre classes de tráfego.

REFERENCES

- [1] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, "Edge computing: Vision and challenges," *IEEE Internet of Things Journal*, vol. 3, no. 5, pp. 637–646, 2016, doi: 10.1109/JIOT.2016.2579198.
- [2] S. W. Fuhrmann and R. B. Cooper, "Stochastic decompositions in the M/G/1 queue with generalized vacations," *Operations Research*, vol. 33, no. 5, pp. 1117–1129, 1985, doi: 10.1287/opre.33.5.1117.
- [3] N. P. Sherman and J. P. Kharoufeh, "An M/M/1 retrial queue with unreliable server," *Operations Research Letters*, vol. 34, no. 6, pp. 697–705, 2006, doi: 10.1016/j.orl.2005.11.003.
- [4] G. Ayyappan and S. Karpagam, "An $M^X/G(a, b)/1$ queueing system with breakdown and repair, stand-by server, multiple vacation and control policy on request for re-service," *Mathematics*, vol. 6, no. 6, art. 101, 2018, doi: 10.3390/math6060101.
- [5] A. M. Law, "Confidence intervals in discrete event simulation: A comparison of replication and batch means," *Naval Research Logistics Quarterly*, vol. 24, no. 4, pp. 667–678, 1977, doi: 10.1002/nav.3800240414.
- [6] K. Hoad, S. Robinson, and R. Davies, "Automated selection of the number of replications for a discrete-event simulation," *Journal of the Operational Research Society*, vol. 61, no. 11, pp. 1632–1644, 2010, doi: 10.1057/jors.2009.121.
- [7] Y. Liu and Y. Q. Zhao, "Asymptotic behavior of the loss probability for an M/G/1/N queue with vacations," *Queueing Systems*, vol. 71, pp. 293–314, 2012, doi: 10.1007/s11134-012-9291-8.