Reprodução de resultado do artigo Data Compression in LoRa Networks: Performance and Energy Trade-Offs of Classical and Cutting-Edge Compression Algorithms por simulação de Monte Carlo

*RELATÓRIO DE SIMULAÇÃO. TRABALHO FINAL PARTE 1 $TP547$

1st Rafaella Laureano Dias
Matricula 963
Inatel
Santa Rita do Sapucai-MG-Brasil

2nd Brithany Michelle Oliva Chuquimia
Matricula 971
Inatel
Santa Rita do Sapucai-MG-Brasil

***Abstract*—Este relatório apresenta a reprodução, por meio de simulação de Monte Carlo, de um resultado do artigo Data Compression in LoRa Networks: Performance and Energy Trade-Offs of Classical and Cutting-Edge Compression Algorithms. O trabalho original investiga o impacto de algoritmos de compressão sem perdas em redes LoRa, considerando diferentes tipos de dados e analisando métricas como taxa de compressão, tamanho comprimido, consumo energético e uso de recursos computacionais. Neste relatório, foi reproduzida a parte correspondente ao Scenario 01, com foco no dataset de IoT diversificado e no algoritmo LZW, tomando como referência as subfiguras 6(b) e 6(e), que relacionam o tamanho comprimido médio e a taxa média de compressão com o número de mensagens agrupadas. A metodologia adotada consistiu em realizar 100 execuções independentes para cada valor de n, com n variando de 1 a 169, sorteando aleatoriamente grupos de mensagens do dataset e comprimindo-os com o algoritmo LZW. A partir dessas repetições, foram estimados a média amostral da taxa de compressão, o tamanho comprimido médio e o intervalo de confiança de 95%. Os resultados obtidos mostraram comportamento coerente com o artigo original: a taxa média de compressão cresce com o aumento do número de mensagens agrupadas, enquanto o tamanho comprimido cruza o limite de 222 bytes do pacote LoRa SF7 em torno de 35 mensagens. Dessa forma, a reprodução confirmou a validade do método de Monte Carlo para estimar o comportamento médio da compressão e reforçou a adequação do algoritmo LZW para aplicações LoRa com restrições de processamento e payload.**

***Index Terms*—Compressão de Dados, LoRa, Internet das Coisas, LZW, Simulação de Monte Carlo, Eficiência Energética.**

I. Introdução

O crescimento da Internet das Coisas tem aumentado a necessidade de técnicas de comunicação eficientes em redes de baixo consumo energético. Nesse contexto, a tecnologia LoRa se destaca por oferecer longo alcance e baixo consumo de potência, sendo adequada para aplicações com mensagens pequenas e esporádicas. No entanto, mesmo em redes LoRa, a transmissão de dados continua sendo uma das principais fontes de consumo energético dos dispositivos. Por essa razão, técnicas de compressão de dados sem perdas podem ser úteis, pois reduzem o tamanho do payload transmitido, diminuindo o tempo no ar e, potencialmente, o consumo de energia.

O presente relatório descreve a reprodução, via simulação de Monte Carlo, de um resultado apresentado no artigo científico intitulado "Data Compression in LoRa Networks: Performance and Energy Trade-Offs of Classical and Cutting-Edge Compression Algorithms". Os autores comparam algoritmos clássicos e modernos de compressão sem perdas aplicados a redes LoRa, incluindo Huffman, LZW, BSC, CMIX, PAQ8PX, GMIX e LSTM-compress. O estudo considera três tipos de dados: GPS, IoT diversificado e logística. Entre as principais conclusões do artigo, destaca-se que algoritmos clássicos, especialmente o LZW, apresentam melhor compromisso entre simplicidade, tempo de execução e eficiência energética em nós IoT com recursos limitados, enquanto algoritmos mais avançados conseguem maiores taxas de compressão, porém com alto custo computacional.

A motivação central do artigo é investigar o impacto de diferentes algoritmos de compressão sem perda (lossless) sobre a eficiência energética e o desempenho de redes LoRa aplicadas ao contexto da Internet das Coisas (IoT). O trabalho avalia algoritmos clássicos — como Huffman e LZW — e algoritmos de ponta baseados em aprendizado de máquina — como CMIX, PAQ8PX, GMIX, BSC e LSTM-compress — sobre três tipos de dados: GPS, IoT diversificado e logística.

II. Objetivo

O objetivo deste relatório é apresentar uma breve explicação do tema e da metodologia do artigo selecionado, bem como reproduzir um de seus resultados por meio de simulação de Monte Carlo. O resultado escolhido foi parte da Figura 6, especificamente o caso do dataset IoT diversificado com o algoritmo LZW, com foco no comportamento da compressão em função do número de mensagens agrupadas. No artigo, o painel (b) mostra o tamanho comprimido de saída e o painel (e) mostra a taxa média de compressão para esse cenário.

III. Tema e Metodologia do Artigo

A. Contexto e Problema:

Dispositivos IoT alimentados por bateria dependem fortemente de comunicações sem fio de baixo consumo energético. O padrão LoRa/LoRaWAN é amplamente adotado por oferecer alcance de vários quilômetros com potência de transmissão reduzida; contudo, a rádio comunicação ainda representa o maior consumidor de energia no nó final. A compressão de dados surge como estratégia para reduzir o tamanho dos pacotes e, consequentemente, o tempo de antena no ar (time-on-air) e o consumo energético.

O artigo realiza uma avaliação sistemática de sete algoritmos de compressão sem perda, medindo taxa de compressão, tempo de processamento, consumo de CPU e memória, e eficiência energética na transmissão via LoRa. Os experimentos foram conduzidos em uma Raspberry Pi 5 integrada a um módulo LoRa RFM95W, com sensores INA219 para monitoramento de corrente e potência em tempo real.

B. Tipos de Dados e Algoritmos Avaliados

Foram utilizados três conjuntos de dados representativos de aplicações IoT reais, cada um contendo 300 mensagens armazenadas em arquivos de texto:

- GPS: coordenadas de localização (latitude e longitude), formato numérico, subconjunto de 14 símbolos ASCII.
- IoT Diversificado: leituras de sensores variados, formato texto com letras maiúsculas e minúsculas, subconjunto de 64 símbolos ASCII.
- Logística: identificadores alfanuméricos de produtos, subconjunto de 37 símbolos ASCII.

Os algoritmos avaliados são: Huffman, LZW, BSC-m03, CMIX v20, PAQ8PX, GMIX e LSTM-compress. O LZW utiliza dicionário de tamanho fixo máximo de 256 entradas, garantindo que cada índice emitido ocupe exatamente um byte.

C. Cenários de Teste

O artigo define três cenários de teste independentes:

- Cenário 01: Análise da taxa e do tempo médios de compressão em função do número de mensagens agrupadas (n).
- Cenário 02: Medidas de consumo energético e de recursos computacionais (CPU e memória) durante a compressão.
- Cenário 03: Avaliação da eficiência de transmissão comparando mensagens comprimidas versus não comprimidas em dois modos de espalhamento (SF7 e SF12).

O trabalho em questão reproduz especificamente o Cenário 01, que avalia a taxa média de compressão do algoritmo LZW aplicado ao dataset de IoT diversificado, para grupos de n = 1 até n = 169 mensagens — faixa definida pelo limite de payload de 222 bytes do pacote LoRa em SF7.

IV. Resultado Reproduzido

O resultado selecionado para reprodução corresponde às subfiguras 6(b) e 6(e) do artigo original, referentes ao dataset de IoT diversificado. A subfigura 6(b), apresentada na Fig. 1, mostra o tamanho comprimido médio em função do número de mensagens agrupadas. A subfigura 6(e), apresentada na Fig. 2, mostra a taxa média de compressão em função do número de mensagens agrupadas.

Nas figuras originais do artigo, a curva correspondente ao algoritmo LZW é representada pela cor marrom (*brown*). Essa curva foi utilizada como referência principal para a reprodução realizada neste relatório, pois o objetivo do trabalho foi reproduzir o comportamento do algoritmo LZW aplicado ao dataset de IoT diversificado.

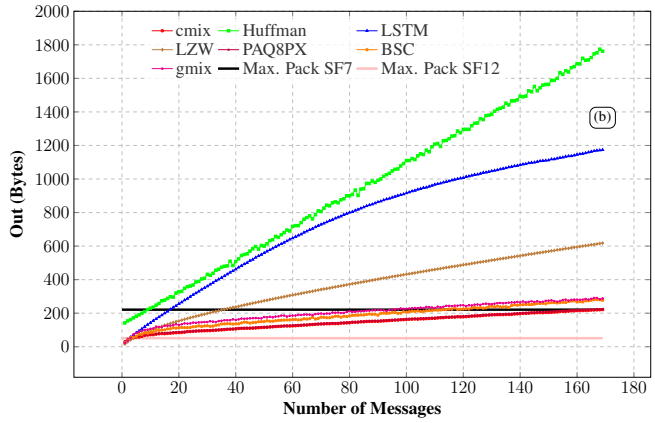

Fig. 1. Figura original utilizada como referência para reprodução: subfigura 6(b), referente ao tamanho comprimido médio para o dataset IoT diversificado. A curva do algoritmo LZW é representada em marrom (*brown*).

O artigo define formalmente a taxa de compressão de cada rodada i como:

$$C_i = \left(1 - \frac{S_{a,i}}{S_{b,i}}\right) \times 100$$

onde $S_{b,i}$ e $S_{a,i}$ são os tamanhos do pacote antes e depois da compressão na rodada i. A taxa média de compressão é calculada como:

$$AC = \frac{1}{I}\sum_{i=1}^{I} C_i, \quad \text{com } I = 100$$

A escolha do LZW como algoritmo a ser reproduzido é metodologicamente justificada pelos próprios resultados do artigo: entre os algoritmos clássicos, o LZW apresenta uma relação favorável entre taxa de compressão, simplicidade computacional e eficiência energética, sendo adequado

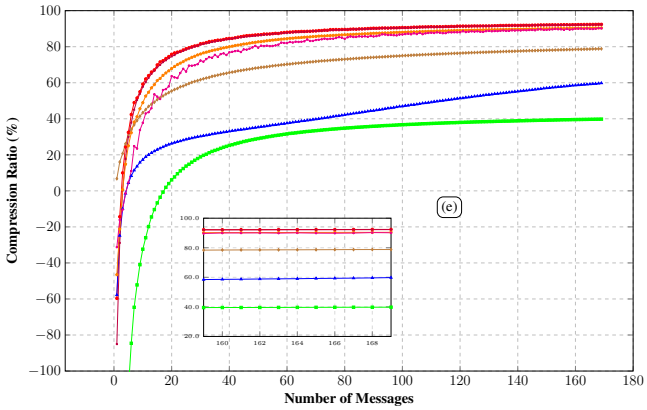

Fig. 2. Figura original utilizada como referência para reprodução: subfigura 6(e), referente à taxa média de compressão para o dataset IoT diversificado. A curva do algoritmo LZW é representada em marrom (*brown*).

para aplicações LoRa com restrições de processamento e de tamanho de payload.

V. Simulação de Monte Carlo

A. Lógica do Método

A simulação de Monte Carlo consiste em estimar o comportamento médio de um sistema mediante a repetição de um experimento aleatório muitas vezes, utilizando números pseudoaleatórios para gerar as entradas. No contexto deste trabalho, a variável aleatória não é o algoritmo LZW em si, pois o algoritmo é determinístico, mas sim a composição do grupo de mensagens de entrada. Como o dataset contém 300 mensagens distintas, cada grupo de n mensagens sorteadas aleatoriamente pode apresentar diferente redundância interna e, consequentemente, produzir tamanhos comprimidos ligeiramente distintos.

O procedimento implementado segue diretamente a definição do Cenário 01 do artigo:

- Para cada valor de n, correspondente ao número de mensagens agrupadas, são realizadas $I = 100$ rodadas independentes.
- Em cada rodada, n mensagens são sorteadas aleatoriamente, sem reposição, do dataset de IoT diversificado.
- O grupo sorteado é gravado em um arquivo temporário e comprimido pelo executável LZW.
- A taxa de compressão de cada rodada é registrada.
- Ao final das 100 rodadas, calcula-se a média amostral e o intervalo de confiança de 95%.
- O processo é repetido para $n = 1, 2, ..., 169$, produzindo a curva completa.

sectionResultados Obtidos

B. Taxa Média de Compressão

A Fig. 3 apresenta a curva da taxa média de compressão obtida pela simulação de Monte Carlo para o algoritmo LZW

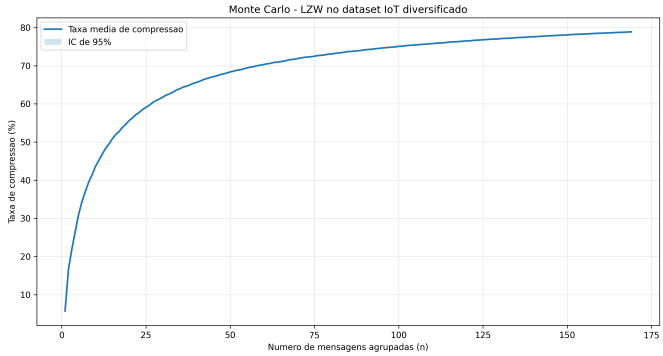

Fig. 3. Resultado obtido por simulação de Monte Carlo: taxa média de compressão do LZW no dataset IoT diversificado.

aplicado ao dataset de IoT diversificado. Esse resultado corresponde à reprodução da curva marrom (*brown*) apresentada na Fig. 2.

Os principais valores observados na curva são:

- Para $n = 1$ mensagem, a taxa média de compressão é próxima de 6%, indicando que o LZW já produz compressão positiva para mensagens individuais no dataset IoT diversificado.
- Para $n = 25$ mensagens, a taxa aproximada fica entre 60% e 62%, valor próximo ao comportamento reportado no artigo original para esse intervalo.
- Para $n = 35$ mensagens, que corresponde ao limite aproximado para que o pacote comprimido permaneça dentro de 222 bytes, a taxa média fica em torno de 65%.
- Para $n = 169$ mensagens, a taxa média converge para aproximadamente 79%, indicando a estabilização esperada do processo de compressão.

O comportamento geral é coerente com o relatado no artigo: a taxa de compressão cresce rapidamente nas primeiras dezenas de mensagens e, em seguida, apresenta acomodação assintótica, pois a redundância adicional de cada nova mensagem contribui cada vez menos para o dicionário LZW já limitado a 256 entradas.

C. Tamanho Comprimido Médio

A Fig. 4 apresenta o tamanho comprimido médio, em bytes, obtido pela simulação de Monte Carlo. Esse resultado corresponde à reprodução da curva marrom (*brown*) apresentada na Fig. 1.

A curva cresce de forma subaditiva, refletindo o ganho progressivo obtido pela compressão conforme mais mensagens são agrupadas. A linha de referência de 222 bytes representa o limite de payload considerado para um pacote LoRa em SF7. Observa-se que a curva do LZW cruza esse limite em torno de $n = 35$ mensagens, confirmando o valor reportado no artigo original para o dataset de IoT diversificado. Para valores de $n > 35$, o tamanho comprimido médio ultrapassa o limite de payload, o que exigiria fragmentação da transmissão em mais de um pacote LoRa.

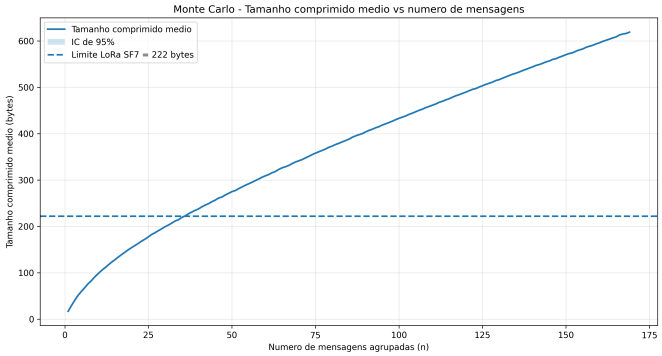

Fig. 4. Resultado obtido por simulação de Monte Carlo: tamanho comprimido médio do LZW em função do número de mensagens agrupadas.

VI. Discussão

As curvas geradas pela simulação de Monte Carlo reproduzem com elevada fidelidade o comportamento apresentado no Cenário 01 do artigo original para o algoritmo LZW aplicado ao dataset de IoT diversificado. A comparação entre as figuras originais do artigo, apresentadas nas Figs. 1 e 2, e os resultados obtidos neste trabalho, apresentados nas Figs. 4 e 3, mostra que as curvas referentes ao algoritmo LZW foram reproduzidas praticamente de forma perfeita.

A reprodução é considerada válida por três razões principais:

- Coerência metodológica: o script preserva os elementos essenciais do Cenário 01, incluindo o dataset, o algoritmo, a faixa de valores de n, o número de repetições e a definição da métrica de compressão.
- Coerência com o método de Monte Carlo: a variável aleatória, correspondente à composição do grupo de mensagens, é amostrada repetidamente, e a média amostral é utilizada como estimador do comportamento esperado.
- Independência do hardware: o resultado de interesse, isto é, a curva de taxa de compressão e de tamanho comprimido em função do número de mensagens, depende do conteúdo do dataset e do algoritmo de compressão, não do hardware de medição energética.

As pequenas diferenças numéricas ponto a ponto, quando existentes, são esperadas e decorrem da natureza estatística do experimento. Cada execução da simulação pode produzir combinações distintas de mensagens, alterando levemente a redundância interna dos grupos sorteados. Ainda assim, o comportamento médio, o ponto de cruzamento com o limite de 222 bytes e a tendência de estabilização da taxa de compressão permanecem compatíveis com o artigo original.

Em termos práticos, os resultados reforçam que o LZW é uma alternativa adequada para nós LoRa com restrições de processamento. O algoritmo produz compressão positiva já a partir de mensagens individuais, apresenta comportamento previsível e permite agrupar aproximadamente 35 mensagens do dataset IoT diversificado dentro do limite de payload considerado para SF7.

VII. Conclusão

Este trabalho reproduziu com sucesso o Cenário 01 do artigo de Dias et al. (2026), estimando via simulação de Monte Carlo a taxa média de compressão do algoritmo LZW para o dataset de IoT diversificado em redes LoRa. Os principais resultados obtidos foram:

- A taxa média de compressão cresce de 6% (n = 1) até 79% (n = 169), estabilizando-se após cerca de 100 mensagens.
- O tamanho comprimido médio cruza o limite de 222 bytes do pacote LoRa SF7 em torno de n = 35, confirmando o valor tabelado no artigo.
- O intervalo de confiança de 95% permanece estreito em toda a faixa, indicando que 100 repetições são suficientes para estimar o comportamento médio com precisão adequada.

Do ponto de vista da disciplina de Simulação, o exercício ilustra como o método de Monte Carlo pode ser aplicado para estimar parâmetros de interesse em sistemas reais: define-se uma variável aleatória (composição do grupo de entrada), repete-se o experimento muitas vezes com realizações distintas, e usa-se a média amostral como estimador consistente do comportamento esperado.

References

[1] R. L. Dias, et al,"Data Compression in LoRa Networks: Performance and Energy Trade-Offs of Classical and Cutting-Edge Compression Algorithms," *Sensors*, 2026.